

信息与知识获取

作业三：多模态自然灾害事件信息抽取系统

设计与实现

实验报告

姓名：XXX 学号：XXXXXXXXXX

2026 年 X 月

目录

1	引言	3
2	系统总体设计	3
2.1	设计思路	3
2.2	技术选型	4
2.3	数据流	4
3	数据采集模块	5
3.1	灾害新闻语料设计	5
3.2	信息图图片生成	5
3.3	文档存储	6
4	文本信息抽取	6
4.1	正则表达式抽取器 (RegexExtractor)	6
4.2	命名实体识别抽取器 (NERExtractor)	7
4.3	依存句法分析抽取器 (DependencyExtractor)	7
4.4	集成抽取器 (EnsembleExtractor)	8
5	多媒体信息抽取 (创新点)	8
5.1	OCR 文字识别	8
5.2	图像色彩场景分析	8
6	跨模态信息融合 (核心创新)	9
6.1	融合策略	9
6.2	融合日志	10
7	事件知识图谱构建	10
7.1	图谱设计	10
7.2	可视化	11
8	抽取结果评价	11
8.1	自动评价	11
8.2	实验结果	11
8.3	多模态融合的增益分析	12

8.4 人工评价	12
9 Web 界面设计	13
10 对环境和社会可持续发展的影响分析	13
10.1 正面影响	13
10.2 潜在风险与应对	13
11 总结与展望	14

1 引言

信息抽取 (Information Extraction, IE) 是自然语言处理领域的核心任务之一, 旨在从非结构化文本中自动识别并提取结构化的事实信息, 如实体、关系和事件。与信息检索侧重于“找到相关文档”不同, 信息抽取更进一步地关注“从文档中提取什么”, 将自由文本中的隐含知识转化为计算机可处理的结构化数据。在突发事件响应、舆情监测、知识图谱构建等应用场景中, 信息抽取技术发挥着不可替代的作用。

传统的信息抽取方法主要依赖单一的文本模态, 通过正则表达式匹配、命名实体识别 (NER)、依存句法分析等技术从文本中提取信息。然而, 现实世界中的信息往往以多种模态呈现——新闻报道配有图片、信息图和视频, 社交媒体帖子包含文字与图像的混合内容。单一文本模态的信息抽取面临信息不完整、上下文不足等局限, 亟需融合多模态数据以提升抽取的准确性和完整性。

本次实验设计并实现了一个**多模态自然灾害事件信息抽取系统**。系统以自然灾害新闻报道为研究对象, 融合**文本分析** (正则表达式 + 命名实体识别 + 依存句法分析) 和**图像处理** (OCR 文字识别 + 色彩场景分析) 两种模态的信息抽取结果, 通过**跨模态置信度加权融合机制**, 从每篇新闻中自动抽取 7 个结构化信息点 (灾害类型、发生时间、发生地点、伤亡情况、经济损失、响应级别、救援组织), 这 7 个信息点共同构成一个完整的“自然灾害事件”。系统还支持从抽取结果中自动构建**事件知识图谱**, 并通过交互式可视化进行展示。在评价方面, 系统同时提供自动评价 (基于 ground truth 计算 Precision / Recall / F1) 和人工评价两种模式。

本报告将按照“系统设计—数据采集—文本抽取—多媒体抽取—跨模态融合—知识图谱—评价分析—创新总结”的逻辑脉络, 详细阐述各模块的设计思想、算法原理与实现细节。

2 系统总体设计

2.1 设计思路

本系统围绕“多模态事件信息抽取”这一核心目标, 构建了六层模块化架构。与传统的纯文本信息抽取系统相比, 本系统引入了图像处理模态和跨模态融合决策层, 形成了文本与图像双通道并行抽取、融合输出的技术路线。

表 1: 系统模块划分

层次	模块名称	主要职责
数据层	数据采集 (crawler.py)	生成/爬取灾害新闻, 生成信息图图片
文本抽取层	文本抽取 (text_extractor.py)	正则 +NER+ 依存分析, 集成投票
图像抽取层	多媒体抽取 (image_extractor.py)	OCR 识别 + 色彩场景分析
融合层	跨模态融合 (fusion.py)	多模态置信度加权融合
知识表示层	知识图谱 (knowledge_graph.py)	事件 KG 构建与 vis.js 可视化
评价层	评价模块 (evaluator.py)	自动评价 + 人工评价
交互层	Web 界面 (app.py)	Flask + Bootstrap 5 界面

2.2 技术选型

表 2: 核心技术依赖

库	版本	用途
jieba	≥ 0.42	中文分词与词性标注 (NER)
Pillow	≥ 9.0	图像生成与处理
Flask	≥ 3.0	Web 应用框架
vis.js	9.x	知识图谱交互式可视化 (CDN)
Bootstrap 5	5.3	前端 UI 组件库 (CDN)
EasyOCR (可选)	≥ 1.7	图像文字识别

2.3 数据流

系统的完整数据流如下: 首先, 数据采集模块生成 (或爬取) 灾害新闻文档, 并为部分文档生成信息图图片; 文本抽取层对文档正文执行三种并行抽取策略 (正则表达式、NER、依存分析), 通过集成投票产生文本侧的抽取结果; 图像抽取层对文档配图执行 OCR 文字识别和色彩场景分析, 得到图像侧的抽取结果; 跨模态融合层将两个模态的结果进行置信度加权融合, 输出最终的结构化事件信息; 知识图谱模块从事件信息中构建实体-关系图谱; 评价模块对抽取结果进行定量评估。系统的总体处理流程如图 1 所示。




图 1: 多模态信息抽取系统流程图

3 数据采集模块

3.1 灾害新闻语料设计

本系统选择**自然灾害事件**作为信息抽取的特定领域。这一选择基于以下考虑：(1) 灾害新闻具有高度结构化的报道模式，信息点清晰可辨；(2) 灾害报道天然包含丰富的多媒体内容（信息图、现场照片等），适合多模态抽取；(3) 灾害信息抽取具有重要的社会应用价值。

系统内置的样本数据生成器覆盖 7 类灾害：**地震、台风、洪水、山体滑坡、火灾、干旱、暴雪**。每类灾害配备了多套新闻报道模板，模板中自然嵌入了 7 个信息点。通过参数随机化（地点、时间、伤亡数字、组织名称等），生成器能够产出 150 篇高仿真、互不重复的灾害新闻文档。每篇文档均附带完整的 ground truth 标注，为后续的自动评价提供了基准。

3.2 信息图图片生成

这是本系统的一个重要创新。为了支持多媒体信息抽取实验，数据生成模块利用 Pillow 库为约 60% 的文档自动生成信息图图片。这些信息图模拟了新闻网站常见的“灾害速报”卡片样式，在图片中以文字形式呈现灾害类型、时间、地点、伤亡数据等信息。信息图采用与灾害类型对应的背景色（如地震为暗红色、洪水为深蓝色、火灾为橙红色），这为后续的色彩场景分析提供了视觉线索。

每张信息图的文字内容同时以元数据形式存储，作为 OCR 回退模式的数据源，确保系统即使在无 OCR 引擎的环境下也能完整演示多媒体抽取流程。

3.3 文档存储

每篇文档以 JSON 格式独立存储,包含 id、title、content、url、date、disaster_type、images、ground_truth 等字段。images 数组中的每个元素包含图片路径、文件名、alt 文本和 OCR 文本。ground_truth 字段记录了所有 7 个信息点的标准答案。

4 文本信息抽取

文本信息抽取是本系统的核心模块,实现了三种互补的抽取策略,并通过加权投票进行集成。

4.1 正则表达式抽取器 (RegexExtractor)

正则表达式匹配是信息抽取的基线方法,也是本课程的基本要求。其优势在于对规范化表述具有高精确率,且无需训练数据。

针对 7 个信息点,系统设计了共计 20 余条正则表达式模式。以下列举部分核心模式:

灾害类型:

```
1 r'发生(?:了)?(?:里氏)?[\d.]+级(地震)'  
2 r'(台风|飓风)(?:"|")?[\u4e00-\u9fa5]+'
```

```
3 r'(森林火灾|草原火灾|山林火灾|火灾)'
```

发生时间:

```
1 r'(\d{4}年\d{1,2}月\d{1,2}日)'
```

伤亡情况 (需要合并多个子模式的匹配结果):

```
1 r'(?:造成|导致)(\d+)人(?:遇难|死亡)'  
2 r'(\d+)人(?:受伤|负伤)'  
3 r'(\d+)人(?:失踪|失联)'
```

经济损失:

```
1 r'(?:直接)?经济损失[约达]?(\d+(?:\.\d+)?) [万亿]元'
```

对于伤亡情况这类需要聚合多个子信息的信息点,系统实现了后处理合并逻辑,将分散匹配的遇难、受伤、失踪人数合并为一条完整的伤亡描述。

4.2 命名实体识别抽取器 (NERExtractor)

第二种抽取策略基于 jieba 的词性标注功能。jieba 能够为每个分词结果标注词性标签（如 ns 表示地名、nt 表示机构名、t 表示时间词），系统利用这些标签定位候选实体，再结合规则进行信息点抽取。

Algorithm 1 基于 NER 的地点信息抽取

输入: 词性标注序列 $W = \{(w_1, f_1), (w_2, f_2), \dots\}$

输出: 事件发生地点 L

```

1: locations  $\leftarrow []$ 
2: for  $(w, f)$  in  $W$  do
3:   if  $f = \text{ns}$  且  $|w| \geq 2$  then
4:     将  $w$  加入 locations
5:   end if
6: end for
7: 从 locations 中识别省级行政区划  $P$  和市级行政区划  $C$ 
8:  $L \leftarrow P + C$  (拼接省市名称)
9: return  $L$ 

```

NER 抽取器的优势在于对非模板化的自然表述具有更好的鲁棒性。例如，对于“甘肃陇南地区”这类不完全符合“省 + 市”模板的地名，NER 能够通过词性标签正确识别。

4.3 依存句法分析抽取器 (DependencyExtractor)

第三种抽取策略利用动词-宾语等句法关系来定位信息点。系统预定义了五类触发词：

- 灾害触发词：发生、遭遇、遭受、袭击、暴发
- 伤亡触发词：造成、导致、致使
- 响应触发词：启动、宣布、发布
- 救援触发词：派出、调派、出动、调集
- 损失触发词：损失、毁损、摧毁

当检测到触发词后，系统在其前后固定窗口内搜索对应的信息点值。例如，当“造成”出现时，在其后文中搜索伤亡数字模式；当“派出”出现时，在其前文中搜索组织机构名称。这种基于事件触发词的抽取策略模拟了事件抽取中的“触发词-论元”框架。

4.4 集成抽取器 (EnsembleExtractor)

三种抽取方法各有优劣：正则表达式精确率高但召回率有限，NER 覆盖面广但可能引入噪声，依存分析结构感知强但实现复杂度较高。系统采用**加权投票融合**将三者的结果集成：

$$v^* = \arg \max_{v \in \text{Candidates}} \sum_{m \in \text{Methods}} w_m \cdot \mathbb{I}[v_m = v] \quad (1)$$

其中 w_m 为各方法的权重（正则 0.4，NER 0.35，依存 0.25）， v_m 为方法 m 的抽取值。当一个候选值被多种方法同时抽取到时，其得分累加，最终得分最高的候选值作为输出。

5 多媒体信息抽取（创新点）

本系统的核心创新在于引入了图像模态的信息抽取，突破了传统纯文本信息抽取的局限。

5.1 OCR 文字识别

新闻配图（尤其是信息图、数据图表）中常包含丰富的文字信息。系统实现了多后端的 OCR 文字识别功能，支持三种引擎：

- **EasyOCR**: 基于深度学习的开源 OCR 引擎，支持中英文识别，可在 CPU 上运行
- **Tesseract**: Google 开源的传统 OCR 引擎，需要单独安装系统组件
- **回退模式**: 当以上引擎均不可用时，利用数据生成阶段保存的图片元数据

OCR 识别出的文字随后被送入与文本抽取相同的正则表达式管道，从图片文字中提取灾害类型、时间、地点等信息点。这实现了“图像 → 文字 → 结构化信息”的跨模态转换。

5.2 图像色彩场景分析

除 OCR 之外，系统还创新性地利用图像的**主色调分布**来推断灾害类型。不同类型的灾害在视觉上具有特征性的色彩倾向：

表 3: 灾害类型与特征色彩对应关系

灾害类型	特征色调
地震	暗红色、棕色（废墟、泥土）
台风/洪水	深蓝色（暴雨、海水）
火灾	橙红色（火焰）
山体滑坡	棕黄色（泥土、岩石）
暴雪	浅灰蓝色（冰雪）
干旱	黄色（干裂的土地）

算法流程如下：

1. 将原始图片缩放至 100×100 像素以降低计算量
2. 将所有像素的 RGB 值量化到 32 级色阶，统计各色阶的频次
3. 提取频次最高的 5 个主色调
4. 将主色调与预设的灾害类型特征色进行欧氏距离匹配
5. 输出距离最近的灾害类型及匹配置信度

主色调与参考色的匹配得分计算公式为：

$$\text{Score}(d) = \sum_{c \in \text{TopColors}} \frac{n_c}{N} \cdot \max \left(0, 1 - \frac{\|c - c_d^{\text{ref}}\|_2}{80} \right) \quad (2)$$

其中 c_d^{ref} 为灾害类型 d 的参考色， n_c 为色阶 c 的像素数， N 为总像素数。

这一方法虽然不如深度学习图像分类精确，但无需 GPU 和预训练模型，计算开销极低，适合作为辅助验证手段与文本抽取结果交叉印证。

6 跨模态信息融合（核心创新）

6.1 融合策略

跨模态融合是本系统最核心的创新。文本和图像两个模态的抽取结果通过以下三种策略进行融合：

1. **信息互补**（Complementation）：当某个模态成功抽取了某信息点而另一模态缺失时，使用已有的结果填补空缺。例如，文本中未明确提及灾害类型，但图片 OCR 中识别出“地震”字样。

2. **交叉验证** (Cross-Validation): 当两个模态的抽取结果一致时, 该信息点的置信度获得提升 (+0.15), 反映了多源信息相互印证的增强效应。
3. **冲突消解** (Conflict Resolution): 当两个模态的结果不一致时, 按各自的置信度加权选择更可靠的结果, 并对最终置信度施加衰减 ($\times 0.8$), 以标识潜在的不确定性。

融合后每个信息点的置信度计算方式为:

$$\text{Conf}^*(p) = \begin{cases} \min(1, 0.6 \cdot c_t + 0.4 \cdot c_i + 0.15) & \text{交叉验证一致} \\ 0.8 \cdot \max(c_t, c_i) & \text{冲突消解} \\ c_t & \text{仅文本模态} \\ 0.9 \cdot c_i & \text{仅图像模态 (补充)} \end{cases} \quad (3)$$

其中 c_t 和 c_i 分别为文本和图像模态的置信度。

6.2 融合日志

系统为每次融合决策记录详细的日志, 包括每个信息点的融合策略选择、各模态的原始值和置信度、最终输出值等。这些日志在 Web 界面中以表格形式展示, 使融合过程完全透明、可解释。

7 事件知识图谱构建

7.1 图谱设计

从抽取的结构化事件信息出发, 系统自动构建事件知识图谱。图谱包含 6 类节点和 6 类边:

表 4: 知识图谱本体设计

节点类型	示例	边类型	含义
事件 (Event)	四川省成都市地震	is_type	事件属于某灾害类型
灾害类型 (DisasterType)	地震	occurred_at	事件发生于某地点
地点 (Location)	四川省成都市	occurred_on	事件发生于某时间
时间 (Time)	2024 年 08 月 15 日	rescued_by	某组织参与救援
组织 (Organization)	中国红十字会	response	启动的响应级别
响应级别 (Level)	II 级	caused	造成的伤亡/损失

7.2 可视化

系统采用 vis.js 开源库实现交互式网络图可视化。不同类型的节点以不同颜色和形状区分（事件为红色星形、地点为蓝色圆形、组织为绿色三角形等），边上标注关系类型。用户可以在浏览器中自由拖拽节点、缩放画布、悬停查看详情，直观地探索灾害事件之间的关联模式（如相同地点的多次灾害、同一组织参与的多次救援等）。

8 抽取结果评价

8.1 自动评价

系统利用数据生成阶段预置的 ground truth 进行自动评价。对每个信息点分别计算精确率（Precision）、召回率（Recall）和 F1 值，然后取所有信息点的宏平均作为整体指标。

由于信息抽取的输出为字符串而非集合，系统采用了分层次的匹配策略：

- **精确匹配**：抽取值与标准答案完全一致， $P = R = F1 = 1.0$
- **部分匹配**：一方为另一方的子串，按重叠比例打分
- **数值匹配**：对伤亡和损失等数值型信息点，提取数字进行集合交集计算
- **集合匹配**：对救援组织等列表型信息点，按集合的 Precision/Recall 计算

8.2 实验结果

在 150 篇文档的数据集上运行批量抽取和自动评价，各信息点的平均指标如表 5 所示。

表 5: 各信息点抽取性能（150 篇文档自动评价）

信息点	Precision	Recall	F1
灾害类型	90.7%	90.7%	90.7%
发生时间	100.0%	100.0%	100.0%
发生地点	82.7%	82.7%	82.7%
伤亡情况	84.8%	84.8%	84.8%
经济损失	100.0%	100.0%	100.0%
响应级别	100.0%	100.0%	100.0%
救援组织	75.7%	100.0%	84.9%
宏平均	90.5%	94.0%	92.2%

从结果可以看出：（1）发生时间、经济损失和响应级别的抽取准确率达到 100%，因为这三类信息在文本中具有高度规范化的表述模式，正则表达式即可精确匹配；（2）灾害类型的准确率为 90.7%，少数误差源于“台风”与“飓风”等近义词的区分以及复合灾害类型的判定；（3）发生地点的准确率为 82.7%，主要挑战在于省市行政区划名称的拼接边界问题；（4）伤亡情况准确率 84.8%，需要合并文中分散出现的遇难、受伤、失踪等信息；（5）救援组织的 Precision 为 75.7% 但 Recall 达到 100%，说明系统能够完整地识别出所有组织，但存在一定的误抽取（如将非救援机构误判为救援组织）。各信息点的 F1 值对比如图 2 所示。




图 2: 各信息点抽取 F1 值对比

8.3 多模态融合的增益分析

为了量化多模态融合带来的增益，我们对比了纯文本抽取与多模态融合抽取的性能差异。对于含有信息图的文档，跨模态交叉验证使灾害类型的平均置信度从 0.72 提升至 0.87，提升了约 21%。在部分文本表述不够明确的案例中，图像 OCR 成功补充了文本模态缺失的时间和地点信息，实现了信息互补。

8.4 人工评价

系统在 Web 界面中为每篇文档的抽取结果提供人工评价入口。用户可以逐个信息点标注“正确/部分正确/错误”三个等级，系统自动计算准确率并保存评价记录。人工评价与自动评价互为补充——自动评价提供大规模快速反馈，人工评价则能更精细地判断边界情况。

9 Web 界面设计

系统的 Web 界面基于 Flask 框架和 Bootstrap 5 构建，提供六个主要页面：

1. **首页**：展示数据集统计信息（文档数、灾害类型分布、含图片文档数等）和系统功能入口。
2. **抽取页面**：列出所有文档，支持单篇抽取和批量抽取操作。
3. **结果列表**：展示已抽取文档的灾害类型、地点、使用的模态等信息。
4. **结果详情**：最丰富的页面，包含原文展示、融合结果表格（带置信度进度条）、融合日志、各方法对比（正则/NER/依存/图像四个 Tab）、人工评价表单。
5. **知识图谱**：vis.js 交互式网络图可视化，附带节点/边统计和灾害类型分布图。
6. **评价页面**：自动评价的 Macro P/R/F1 大数字卡片，各信息点的详细指标表格，评价历史。

10 对环境和社会可持续发展的影响分析

10.1 正面影响

灾害应急响应：自动化的灾害事件信息抽取能大幅缩短灾情信息收集与研判时间。在重大自然灾害发生后，从海量新闻中快速提取结构化的伤亡、经济损失和响应级别信息，可为应急指挥部门提供及时的决策支撑，有助于减少灾害损失和人员伤亡。

防灾减灾知识积累：通过知识图谱系统性地整理历史灾害事件信息，有助于发现灾害发生规律和高风险区域，为城市规划、基础设施抗灾设计和保险精算提供科学依据，助力实现联合国可持续发展目标 SDG 11（可持续城市和社区）和 SDG 13（气候行动）。

绿色计算：系统采用轻量级的 NLP 和图像分析算法组合（jieba + 正则 + Pillow），无需 GPU 集群，在普通笔记本电脑上即可运行全部功能。与基于大规模深度学习模型的方案相比，计算资源消耗和碳排放大幅降低。

10.2 潜在风险与应对

信息准确性：自动抽取可能存在误差，在实际应急场景中关键决策仍需人工核验。系统提供了人工评价接口和可解释的融合日志，确保结果的可审计性。

隐私保护：灾害新闻中可能涉及受灾群众个人信息。系统在设计中注意数据脱敏，抽取的信息点聚焦于宏观事件层面（伤亡人数、经济损失总量），不涉及个人身份信息。

11 总结与展望

本次实验设计并实现了一个多模态自然灾害事件信息抽取系统，在完成课程基本要求的基础上进行了多项创新性探索：

1. **多策略文本抽取：**实现了正则表达式、NER 和依存分析三种抽取策略，并通过加权投票集成，提升了单一方法的鲁棒性。
2. **多媒体信息抽取：**引入图像 OCR 文字识别和色彩场景分析两种图像抽取技术，突破了纯文本信息抽取的局限。
3. **跨模态融合：**设计了基于置信度加权的模态融合引擎，实现了信息互补、交叉验证和冲突消解三种策略。
4. **事件知识图谱：**从抽取结果自动构建事件知识图谱，并通过 vis.js 实现交互式可视化探索。
5. **双模式评价：**同时支持自动评价（P/R/F1）和人工评价，为系统性能提供了全面的量化分析。

实验结果表明，系统在 150 篇文档上取得了 **92.2%** 的宏平均 F1 值（Precision 90.5%，Recall 94.0%），其中发生时间、经济损失和响应级别三个信息点达到了 100% 的准确率。多模态融合对含图片文档的灾害类型识别置信度提升了约 21%，验证了跨模态信息互补的有效性。

未来可在以下方向深入探索：（1）引入预训练语言模型（如 BERT-NER）提升文本抽取的精度，特别是对组织名称和复杂地名的识别；（2）采用深度学习图像分类模型（如 ResNet、CLIP）替代色彩启发式分析，实现更精确的灾害场景识别；（3）接入实时新闻 API 实现在线抽取和监测；（4）结合 GIS 地理信息系统实现灾害事件的空间可视化。

参考文献

- [1] Jurafsky D, Martin J H. *Speech and Language Processing*. 3rd ed. 2024.

- [2] Manning C D, Raghavan P, Schütze H. *Introduction to Information Retrieval*. Cambridge University Press, 2008.
- [3] Grishman R. Information Extraction: Techniques and Challenges. *Information Extraction*, Springer, 1997: 10–27.
- [4] Ahn D. The Stages of Event Extraction. *Proceedings of the Workshop on Annotating and Reasoning about Time and Events*, ACL, 2006.
- [5] Chen Y, Xu L, Liu K, et al. Event Extraction via Dynamic Multi-Pooling Convolutional Neural Networks. *Proceedings of ACL*, 2015: 167–176.
- [6] Li M, Zareian A, Zeng Q, et al. Cross-media Structured Common Space for Multimedia Event Extraction. *Proceedings of ACL*, 2020: 2557–2568.
- [7] Tong M, Xu B, Wang S, et al. Improving Event Detection via Open-domain Trigger Knowledge. *Proceedings of ACL*, 2020: 5887–5897.
- [8] jieba 中文分词. <https://github.com/fxsjy/jieba>.
- [9] EasyOCR: Ready-to-use OCR. <https://github.com/JaidedAI/EasyOCR>.
- [10] Flask Web Framework. <https://flask.palletsprojects.com/>.
- [11] vis.js – Dynamic, browser-based visualization library. <https://visjs.org/>.
- [12] Pillow: Python Imaging Library. <https://pillow.readthedocs.io/>.