

面向灾害新闻的信息抽取系统

(信息与知识获取 · 作业三实验报告)

2026 年 6 月

姓名	学号	角色	分工
曹忠昊	2023211964	组长	灾害语料爬虫与三重过滤、系统集成抽取算法（正则 / 触发词 / NER 加权投票）与知识图谱
侯钧译	2023211728	组员	EasyOCR 多媒体抽取、人工评价与实验报告
徐舸山	2023211038	组员	

摘要

本作业实现了一个面向真实灾害新闻的信息抽取系统。系统从政府与通讯社等权威来源采集了 118 篇真实灾害报道并本地存储，对每篇报道抽取灾害类型、发生时间、发生地点、伤亡情况、经济损失、响应级别与救援信息共 7 个信息点，并将其组装为一个结构化的灾害事件。抽取方法以正则匹配为基础，并在此之上构建集成：正则、触发词与基于 jieba 词性标注的命名实体识别三路并行，按字段加权投票，消融实验表明集成相对纯正则将平均填充字段数提升约 4.8%。事件进一步聚合为知识图谱。在文本之外，系统先以视觉大模型（Qwen-VL）对配图进行质检、剔除 logo、二维码、UI 等无关图，再对保留的真实灾情图以 EasyOCR 识别文字并回灌至抽取，属图像与文本结合的多媒体信息抽取尝试。抽取结果支持逐字段的人工评价。除从零运行 OCR 需首次联网下载模型外，全流程在 CPU 上运行，且不含任何编造数据。

1 任务背景与总体设计

信息抽取的目标，是从非结构化文本中抽取所关注的特定信息点，并整理为结构化形式。本次作业的基本要求为：选定一个特定领域，以爬虫采集不少于 100 篇文档并本地存储，对感兴趣的信息点进行抽取与展示，信息点不少于 5 个且能组合为一个事件，可调用开源的中英文 NLP 基本模块，抽取算法至少实现正则表达式匹配，并尽量对结果准确率进行人工评价；扩展要求则鼓励尝试多媒体抽取与算法优化。

本系统选定的领域为灾害事件。一条灾害新闻天然适合做信息抽取：其通常会交代灾害类型、发生的时间与地点、造成的伤亡与损失、启动的应急响应级别以及参与的救援力量。将上述要素归纳为 7 个信息点，恰可组合成一个完整的灾害事件，亦超过了「不少于 5 个」的要求。在抽取算法上，除必需的正则匹配外，另引入触发词与命名实体识别两路，构成加权投票的集成，这是本系统主要的算法投入；所用 NLP 基本模块为 jieba 的分词、词性标注与分句。系统的整体流程如图 1 所示。




图 1: 系统流程: 爬虫采集灾害语料, 配图经 VLM 质检与 OCR 后文字回灌, 集成抽取产出 7 要素事件, 再聚合为知识图谱并支持逐字段人工评价。

2 灾害语料采集

灾害领域的语料采集不应只追求数量, 更须保证入库内容「确为灾害事件」。系统在通用异步爬虫的基础上进行了主题聚焦与质量过滤, 最终入库 118 篇真实灾害报道, 去重后覆盖 19 个域名、14 个来源, 全部为政府与通讯社等权威源。来源较多者为四川省政府 (22)、应急管理部 (22)、水利部 (12)、人民网 (12)、新华网 (10)、中国地震局 (8)、中国新闻网 (7)、澎湃新闻 (7); 按灾害类型划分为地震 39、洪水 33、暴雨 25、台风 11、火灾 5、山体滑坡 3、暴雪 2, 共 7 类。每篇文档均保留原始 URL、来源与日期, 可逐条溯源; 图片路径统一规范化为 `data/images/` 下的相对路径, 不含机器绝对路径, 整个项目可直接迁移; 项目中亦已删除一切数据生成器, 不含伪造文档。

过滤环节尤为关键, 因为它直接决定了语料的「事件纯度」。早期版本曾从地震局等站点的链接中带回大量机构话术页面, 如党组读书班、警示教育、巡视通报、座谈调研、监测站简介、信息公开年报、网站地图等; 这些页面虽在字面上含灾害关键词, 却并非灾害事件。为此, 在原有的灾害特征判断与真实性校验之外, 增加了一道事件性过滤: 要求标题中出现具体的灾害事件或响应信号 (如震级、启动响应、遇难、受灾、登陆、强降雨、防汛、救灾资金等), 并将党务、会议、解读、年报、导航、人名等机构话术标题排除在外。配合来源白名单与单源配额, 最终保留者即为真实灾害事件而非部门工作动态。爬虫本身仍采用异步并发、礼貌抓取与 SimHash 去重, 配图按 PNG/JPG 文件头校验后落盘, 为后续 OCR 提供素材。

3 信息抽取方法

3.1 七个信息点

系统抽取的 7 个信息点及其主要抽取手段见表 1。需要澄清的是, 「信息点不少于 5 个」指的是系统定义并抽取的信息点种类, 即事件模板的槽位数, 此处为 7 个; 单篇报道最终填充的字段数则取决于该报道自身的信息含量, 这一点将在实验结果中如实讨论。

3.2 集成抽取与加权投票

单一正则存在两方面不足: 表述灵活时易漏抽 (召回不足), 有时又会抽取到不应抽取的内容 (精度受限)。为此, 系统将三个互补的抽取器组合, 按字段加权投票。正则引擎模式精确, 主要负责响应级别、伤亡数字、经济损失金额等格式性较强的字段, 其权重基线较高 (0.6); 触发词引擎基于触发词与上下文窗口, 补充正则覆盖不到的自然语言表述; NER 引擎以 jieba 的词性标注

表 1: 七个信息点与主要抽取手段

信息点	含义	主要抽取手段
灾害类型	地震 / 台风 / 洪水 / 暴雨 / 火灾……	正则 + 触发词
发生时间	日期 / 时段	正则 + NER (时间)
发生地点	省市县 / 震中	NER (地名) + 正则
伤亡情况	死亡 / 受伤 / 失踪人数	正则
经济损失	直接经济损失金额	正则
响应级别	— 级应急响应	正则
救援信息	转移 / 搜救 / 救灾力量	触发词 + NER (机构)

(`jieba.posseg`) 识别人名、地名、机构与时间，再由领域规则补全完整的行政区划与救援机构，主要补充地点、机构与时间字段。

此处一项实现上的取舍值得说明：原计划采用百度 LAC 进行 NER，但实际部署环境中并未安装 LAC，若强行依赖，NER 一路将静默退化为正则兜底，使「采用 NER」名实不符。权衡之后，改用更易获得的 `jieba.posseg` 作为默认的开源 NER，并将 LAC 降为可选增强（安装后自动启用）。如此，在任意环境下 NER 一路均确实调用了开源 NLP 模块，而非徒有其名。`jieba` 的词性标注对机构名与细粒度地名召回偏弱，此部分恰由领域规则补足，二者互补。

投票流程如下：对每个字段先收集各抽取器给出的候选，按归一化与子串包含关系将同义候选合并成组，再取累计权重最高的一组。若记字段 f 上产生候选的抽取器集合为 M_f 、胜出候选所在的组为 G^* ，则该字段的集成置信度定义为

$$\text{conf}(f) = \frac{\sum_{m \in G^*} w_{f,m}}{\sum_{m \in M_f} w_{f,m}}, \quad (1)$$

即胜出组的权重占所有给出候选的抽取器权重之比。每个字段最终均附带该置信度与来源标注（如 `regex+ner`）在网页上展示。

以发生地点为例（该字段三个抽取器的权重为正则 0.45、触发词 0.30、NER 0.40）。若正则与 NER 均抽到「甘肃临夏州积石山县」，二者归并为同一组、权重合计 0.85，无竞争候选，置信度即为 $0.85/0.85 = 1.0$ ；若正则抽到「甘肃临夏州积石山县」而 NER 抽到「青海」，两组权重分别为 0.45 与 0.40，前者胜出，置信度为 $0.45/0.85 \approx 0.53$ ，该偏低取值恰好提示此字段存在分歧、需人工复核。网页再据此为字段着色（绿 ≥ 0.8 、橙 ≥ 0.5 、灰更低），相当于为人工评价提供优先级提示：绿色可快速通过，橙、灰则需重点核对。针对 NER 常见的边界噪声（如将「当日」「日从」等前缀并入实体），系统以规则进行清洗；发生地点还专门做了行政区划规范化——以省份名锚定抽取最长的行政链，剥离「在 / 家住 / 造成」等非地名引导词，合并重复的行政后缀，并剔除「重点地区 / 南方地区」等泛化表述，遵循宁缺毋滥的原则，不输出含噪取值。

3.3 消融实验

为量化集成相对纯正则的收益，在同一份语料上对比了两者的平均填充字段数：纯正则为 3.70，集成为 3.88，提升约 4.8%。增益主要集中于发生地点、救援信息、伤亡情况等表述灵活的「软」字段——这些字段由 NER 补充地名与机构、由触发词补充自然语言表述；尤其是发生地点，在

正则被规范化严格收紧之后，干净候选更多来自触发词与 NER。而响应级别、灾害类型等格式性较强的字段，正则本已能高精度命中，集成在此主要起加权去噪与给出置信度的作用。

4 事件组装与知识图谱

抽取所得的字段被组装为一个结构化的灾害事件，并附带严重程度定级、信息完整度、缺失字段列表与一句摘要。进一步地，将这些事件聚合为知识图谱：节点包括事件、地点、灾害类型、机构、时间等，边连接事件与其各要素。当前图谱共 386 个节点、641 条关系，其中事件节点 105 个（即 107 篇有效事件中有 105 篇要素足够充分、成功建立了事件节点）。前端以 ECharts 力导向图展示，可按类型或地区进行态势观察。

5 多媒体信息抽取：VLM 图片质检与 OCR

灾害新闻页所抓取的「配图」中混有大量与灾情无关的噪声，如站点 logo、二维码、UI 图标、广告横幅、纯文字海报等。若不加甄别直接 OCR，既会使配图展示混杂，也会让「图片文字」充斥从 logo、二维码识别出的无意义字符。为此，配图分两步处理。

5.1 VLM 图片质检

将每张配图降采样至 512px，送入视觉大模型（通义千问 qwen3-vl-plus，经 DashScope 的 OpenAI 兼容接口），由其判断是否为一张「有意义的灾害新闻内容图」，仅输出 {keep, type, reason}。判定结果按文件名缓存至 data/vectors/vlm_verdicts.json，随交付一并分发——即便批改环境无密钥，也能复现「已清洗」的结果；判定失败时采取 fail-open 默认保留，密钥仅从环境变量读取、不写入任何文件。全库 91 张配图送检，剔除 71 张：网站 logo 25、二维码 10、装饰图 7、UI 图标 6、与灾害无关的文字海报 5 等，最终保留 20 张真实灾情内容图（分布于 12 篇文档）。该方法与作业二的图片质检同源，仅将提示词调整为灾害题材。

一个值得说明的现象是：权威灾害通报页中的「配图」约八成为站点 logo、二维码、UI 等页面装饰，而非灾情照片。VLM 质检可将其与真正的内容图有效区分，使 OCR 与配图展示不再被噪声淹没。

5.2 OCR 识别与回灌

对通过质检的内容图，采用 EasyOCR（ch_sim+en，纯 CPU，置信度阈值 0.3）识别文字，再将 OCR 文本以「【图片文字】」的形式拼接至正文之后，一并参与集成抽取。质检之后有 8 篇文档获得了真正来自灾情图的 OCR 文本。识别结果缓存至 ocr_cache.json，演示时即时加载；OCR 页面另提供「实时重新识别」按钮，可现场验证识别为在线实时运行而非预置。

此处补充一组对照：将无关图的 OCR 文本从抽取输入中剔除后，7 要素的抽取结果完全一致（有效事件、平均填充、各字段填充率均与剔除前相同），说明灾情要素本就出自正文；先前「82 篇参与 OCR」中绝大多数实为对 logo、二维码等噪声的识别。剔除之后「参与 OCR」由 82 降至 8，为更准确的口径，知识图谱亦相应由 388/643 微调至 386/641。

实现中还遇到一个较为隐蔽的问题：EasyOCR 底层以 cv2.imread 读图，而其在 Windows 上无法读取中文路径，会静默返回空值、随后报 NoneType 无 shape。由于项目路径包含中文，OCR

一度整体失效。解决方法为改用 `PIL.Image` 读图、转为 `numpy` 数组再输入 `EasyOCR`，以避开 `OpenCV` 对中文路径的限制。

6 实验结果

6.1 抽取覆盖率

118 篇文档上各字段的填充率见表 2。平均填充 3.88 个字段，其中 107 篇（91%）凑齐关键要素、计为有效事件。

表 2: 各信息点在 118 篇上的填充率

信息点	填充率	说明
灾害类型	118/118（100%）	入库即要求命中灾害类型
发生时间	103/118（87%）	正则多模式 + NER（时间）
发生地点	85/118（72%）	NER 与正则协同，经规范化只保留具体行政区划
救援信息	80/118（68%）	触发词 + 机构；权威源重点报道处置与救援力量
响应级别	49/118（42%）	启动应急响应的事件含；支持中文「四级」→ 级归一化
伤亡情况	14/118（12%）	含具体伤亡数字的事件
经济损失	9/118（8%）	披露直接经济损失金额的事件

上表有两点值得说明。其一，伤亡与经济损失的填充率明显偏低，这并非抽取缺陷，而是真实信息源的特点：权威媒体的即时通报往往先明确灾害类型、时间、地点与响应级别，具体的伤亡与损失数字通常须待后续跟踪报道方才披露；如实呈现这一现象较之强行凑数更为客观，亦符合「不编造数据」的要求。其二，发生地点的 72% 为规范化收紧后的结果：在行政区划规范化之前，地点字段填充率表面可达 94%，但其中混有「家住某县县」「部署重点地区」「南方地区」等噪声；规范化之后收敛至 72%，但所余均为干净、具体的行政区划。此处以少量召回换取精度，因为在人工评价中含噪地点将被直接判错，得不偿失。

6.2 人工评价

抽取结果页的每个字段旁均设有「正确 / 部分 / 错误」三个按钮，评分者点击后分别按 1.0 / 0.5 / 0.0 计分，系统实时返回本次的准确率与逐字段统计并写入评价库，可在汇总页按字段聚合查看。交付版本中评价库为干净的初始状态，分数由评分者现场打出，是真实记录而非预置。

7 对环境与社会可持续发展的影响

在环境方面，爬虫的异步并发与礼貌抓取减少了无效请求，`SimHash` 去重避免了重复存储，抽取结果、OCR 与图谱均一次构建、持久化复用；所用 `EasyOCR`、`jieba` 等模型对 CPU 友好，整体算力与能耗较低。在社会方面，将散落于新闻中的灾情要素自动结构化、再关联为事件图谱，可为应急响应与防灾减灾提供线索，服务公共安全；OCR 补充了图片中的灾情信息，提升了应急信息的完整度。系统内设 `/sustainability` 页面对此作了说明。

8 局限与展望

伤亡与经济损失的填充率受信息源披露习惯的限制，后续可引入跨文档事件归并，将同一灾害的即时通报与后续跟踪报道相关联以补全数字。NER 目前为 jieba 词性标注加领域规则，灾害领域的专名（细粒度地名、救援机构）还可借助领域词典、微调，或在有条件时接入 LAC、HanLP 予以增强。知识图谱亦可进一步实现事件去重与时序链构建，以支撑同一灾害多篇报道的聚合。

9 运行与复现

系统已附带抽取结果、知识图谱与 OCR 缓存，开箱即可启动：

```
pip install -r requirements.txt
python run.py web # 启动 Web, 默认 http://127.0.0.1:8090
# 从零构建（可选）：
python run.py crawl --max 400 # 异步爬取真实灾害新闻
python run.py ocr # EasyOCR 识别配图文字并回灌
python run.py extract # 全量集成抽取 + 构建知识图谱
```

启动后可访问抽取、知识图谱、OCR 抽取、抽取评价与可持续等页面。NER 默认使用 jieba，无需联网下载；仅从零运行 OCR 或「实时重新识别」时，首次会联网下载 EasyOCR 模型，之后离线复用。