

面向灾害新闻的信息抽取系统

(信息与知识获取 · 作业三实验报告)

2026 年 6 月

姓名	学号	角色	分工
曹忠昊	2023211964	组长	灾害语料爬虫与三重过滤、系统集成抽取算法（正则 / 触发词 / NER 加权投票）与知识图谱 EasyOCR 多媒体抽取、人工评价与实验报告
侯钧译	2023211728	组员	
徐舸山	2023211038	组员	

摘要

本作业实现了一个面向真实灾害新闻的信息抽取系统。系统从政府与通讯社等权威来源采集了 118 篇真实灾害报道并本地存储，对每篇报道抽取灾害类型、发生时间、发生地点、伤亡情况、经济损失、响应级别与救援信息这 7 个信息点，并把它们组装成一个结构化的灾害事件。抽取方法以正则匹配为基础，在此之上做了集成：正则、触发词与基于 jieba 词性标注的命名实体识别三路并行，按字段加权投票，消融实验显示集成相对纯正则把平均填充字段数提升了约 4.8%。事件进一步聚合为知识图谱。在文本之外，系统先用视觉大模型（Qwen-VL）对配图做质检、剔除 logo、二维码、UI 等无关图，再对保留的真实灾情图用 EasyOCR 识别文字并回灌进抽取，是图像与文本结合的多媒体信息抽取尝试。抽取结果支持逐字段的人工评价。除从零跑 OCR 需要首次联网下载模型外，全流程在 CPU 上运行，且不含任何编造数据。

1 任务背景与总体设计

信息抽取要做的，是从非结构化的文本里把我们关心的特定信息点抽出来，整理成结构化的形式。本次作业的基本要求是：选定一个特定领域，用爬虫采集不少于 100 篇文档并本地存储，对感兴趣的信息点做抽取并展示，信息点不少于 5 个且能组合成一个事件，可以调用开源的中英文 NLP 基本模块，抽取算法至少要实现正则表达式匹配，并尽量对结果准确率做人工评价；扩展要求鼓励尝试多媒体抽取与算法优化。

我们选的领域是灾害事件。一条灾害新闻天然适合做信息抽取：它通常会交代是什么灾、发生在何时何地、造成了多少伤亡和损失、启动了几级应急响应、有哪些救援力量参与。我们把这些归纳成 7 个信息点，它们恰好能拼成一个完整的灾害事件，也超过了「不少于 5 个」的要求。在抽取算法上，除了必需的正则匹配，我们还加了触发词和命名实体识别两路，做成加权投票的集成，这是本系统主要的算法投入；NLP 基本模块用的是 jieba 的分词、词性标注与分句。系统的整体流程见图 1。




图 1: 系统流程: 爬虫采集灾害语料, 配图经 VLM 质检与 OCR 后文字回灌, 集成抽取产出 7 要素事件, 再聚合为知识图谱并支持逐字段人工评价。

2 灾害语料采集

灾害领域的语料采集不能只追求数量, 更要保证「确实是灾害事件」。我们在通用异步爬虫的基础上做了主题聚焦和质量过滤, 最终入库 118 篇真实灾害报道, 去重后覆盖 19 个域名、14 个来源, 全部是政府与通讯社等权威源。来源较多的有四川省政府 (22)、应急管理部 (22)、水利部 (12)、人民网 (12)、新华网 (10)、中国地震局 (8)、中国新闻网 (7)、澎湃新闻 (7); 按灾害类型分, 地震 39、洪水 33、暴雨 25、台风 11、火灾 5、山体滑坡 3、暴雪 2, 共 7 类。每篇文档都保留原始 URL、来源与日期, 可逐条溯源; 图片路径统一规范化成 `data/images/` 下的相对路径, 不含机器绝对路径, 整个项目可以直接迁移; 代码里也删除了一切数据生成器, 没有伪造文档。

值得一提的是过滤这一环, 因为它直接决定了语料的「事件纯度」。最初版本从地震局等站点的链接里带回了大量机构话术页面——党组读书班、警示教育、巡视通报、座谈调研、监测站简介、信息公开年报、网站地图等, 这些页面字面上含灾害关键词, 却根本不是灾害事件。为此我们在原有的灾害特征判断和真实性校验之外, 加了一道事件性过滤: 要求标题里出现具体的灾害事件或响应信号 (震级、启动响应、遇难、受灾、登陆、强降雨、防汛、救灾资金等), 同时把党务、会议、解读、年报、导航、人名这类机构话术标题挡在外面。配合来源白名单和单源配额, 最终留下的才是真实灾害事件而非部门工作动态。爬虫本身仍是异步并发、礼貌抓取、SimHash 去重, 配图按 PNG/JPG 文件头校验后落盘, 为后面的 OCR 提供素材。

3 信息抽取方法

3.1 七个信息点

系统抽取的 7 个信息点及其主要抽取手段见表 1。需要澄清的是, 「信息点不少于 5 个」指的是系统定义并抽取的信息点种类, 也就是事件模板的槽位数, 这里是 7 个; 至于某一篇报道最终填满几个, 取决于这条新闻本身写了多少, 这一点会在实验结果里如实讨论。

3.2 集成抽取与加权投票

单靠正则有两个毛病: 表述一灵活就漏抽 (召回不足), 有时又会抽到不该抽的 (精度受限)。所以我们将三个互补的抽取器组合起来, 按字段加权投票。正则引擎模式精确, 主攻响应级别、伤亡数字、经济损失金额这类格式很强的字段, 权重基线设得较高 (0.6); 触发词引擎基于触发词加上上下文窗口, 补正则覆盖不到的自然语言表述; NER 引擎用 jieba 的词性标注 (`jieba.posseg`)

表 1: 七个信息点与主要抽取手段

信息点	含义	主要抽取手段
灾害类型	地震 / 台风 / 洪水 / 暴雨 / 火灾……	正则 + 触发词
发生时间	日期 / 时段	正则 + NER (时间)
发生地点	省市县 / 震中	NER (地名) + 正则
伤亡情况	死亡 / 受伤 / 失踪人数	正则
经济损失	直接经济损失金额	正则
响应级别	— 级应急响应	正则
救援信息	转移 / 搜救 / 救灾力量	触发词 + NER (机构)

识别人名、地名、机构和时间，再用领域规则补全完整的行政区划与救援机构，主要补地点、机构和时间。

这里有一个实现上的取舍值得说明。我们原本打算用百度的 LAC 做 NER，但实际部署环境里并没有装 LAC，如果硬依赖它，NER 这一路就会静默退化成正则兜底，报告里写的「用了 NER」就名不副实了。权衡之后，我们改用随处可得的 `jieba.posseg` 作为默认的开源 NER，把 LAC 降级为「装了才用」的可选增强。这样无论在什么环境下，NER 这一路都确实在调用一个开源 NLP 模块，而不是挂个名头。`jieba` 的词性标注对机构名和细粒度地名召回偏弱，这部分正好由领域规则补上，二者互补。

投票的具体流程是：对每个字段先收集各抽取器给出的候选，按归一化和子串包含关系把同义候选合并成组，再取累计权重最高的那一组。若记字段 f 上产生了候选的抽取器集合为 M_f 、胜出候选所在的组为 G^* ，则该字段的集成置信度定义为

$$\text{conf}(f) = \frac{\sum_{m \in G^*} w_{f,m}}{\sum_{m \in M_f} w_{f,m}}, \quad (1)$$

即胜出组的权重占所有发声抽取器权重的比例。每个字段最终都带着这个置信度和来源标注（如 `regex+ner`）展示在网页上。

举个发生地点的例子（该字段三个抽取器的权重为正则 0.45、触发词 0.30、NER 0.40）。若正则与 NER 都抽到「甘肃临夏州积石山县」，两者归并为同一组、权重合计 0.85，没有竞争候选，置信度即 $0.85/0.85 = 1.0$ ；但若正则抽到「甘肃临夏州积石山县」、NER 却抽到「青海」，两组权重为 0.45 与 0.40，前者胜出，置信度为 $0.45/0.85 \approx 0.53$ ——这个偏低的价值恰好提示该字段存在分歧、值得人工复核。页面再据此给字段着色（绿 ≥ 0.8 、橙 ≥ 0.5 、灰更低），相当于替人工评价排好了优先级：绿色的可以快速放过，橙、灰的重点核对。对 NER 常见的边界噪声（比如把「当日」「日从」之类前缀粘连进实体），我们用规则做了清洗；发生地点还专门做了行政区划规范化——以省份名锚定抽取最长的行政链，剥掉「在 / 家住 / 造成」这类非地名引导词，合并重复的行政后缀，并剔除「重点地区 / 南方地区」这种泛化表述，宁可少给也不给脏数据。

3.3 消融实验

为了量化集成相对纯正则的收益，我们在同一份语料上对比了两者的平均填充字段数：纯正则为 3.70，集成为 3.88，提升约 4.8%。增益主要集中在发生地点、救援信息、伤亡情况这几个

「软」字段上——这些字段表述灵活，靠 NER 补地名机构、靠触发词补自然语言说法；尤其是发生地点，在正则被规范化严格收紧之后，干净候选更多来自触发词和 NER。而响应级别、灾害类型这类强格式字段，正则本就能高精度命中，集成在这里的作用更多是加权去噪、给出置信度。

4 事件组装与知识图谱

抽取出来的字段会被组装成一个结构化的灾害事件，附带严重程度定级、信息完整度、缺失字段列表和一句摘要。进一步地，我们把这些事件聚合成知识图谱：节点包括事件、地点、灾害类型、机构、时间等，边把事件和它的各个要素连起来。当前图谱共 386 个节点、641 条关系，其中事件节点 105 个（即 107 篇有效事件中有 105 篇要素足够充分、成功建立了事件节点）。前端用 ECharts 的力导向图展示，可以按类型或地区做态势上的观察。

5 多媒体信息抽取：VLM 图片质检与 OCR

灾害新闻页抓来的「配图」里混着大量与灾情无关的噪声——站点 logo、二维码、UI 图标、广告横幅、纯文字海报等。如果不加甄别直接 OCR，既会让配图展示一团乱，也会让「图片文字」里塞满从 logo、二维码识别出的乱码。所以配图我们分两步处理。

5.1 VLM 图片质检

把每张配图降到 512px，送进视觉大模型（通义千问 qwen3-vl-plus，经 DashScope 的 OpenAI 兼容接口），让它判断这是不是一张「有意义的灾害新闻内容图」，只输出 {keep, type, reason}。判定结果按文件名缓存到 data/vectors/vlm_verdicts.json，随交付一起分发——即便批改环境没有密钥，也能复现「已清洗」的结果；判定失败则 fail-open 默认保留，密钥只从环境变量读取、不写入任何文件。全库 91 张配图送检，剔除了 71 张：网站 logo 25、二维码 10、装饰图 7、UI 图标 6、与灾害无关的文字海报 5 等，最终保留 20 张真实灾情内容图（分布在 12 篇文档里）。这套做法与作业二的图片质检同源，只是把提示词换成了灾害题材。

一个有点出乎意料、但值得如实写下的发现是：权威灾害通报页里的「配图」大约八成是站点 logo、二维码、UI 这类页面装饰，而不是灾情照片。VLM 质检把它们和真正的内容图干净地分开了。

5.2 OCR 识别与回灌

对通过质检的内容图，我们用 EasyOCR（ch_sim+en，纯 CPU，置信度阈值 0.3）识别文字，再把 OCR 文本以「【图片文字】」的形式拼接到正文之后，一起参与集成抽取。质检之后有 8 篇文档获得了真正来自灾情图的 OCR 文本。识别结果缓存到 ocr_cache.json，演示时秒开；OCR 页面还提供「实时重新识别」按钮，可以现场验证识别确实是在线跑出来的，而不是预置的。

这里要补一个诚实的对照：把无关图的 OCR 文本从抽取输入里去掉后，7 要素的抽取结果完全没变（有效事件、平均填充、各字段填充率都和去掉前一致）。这说明灾情要素本来就出自正文，而先前「82 篇参与 OCR」里绝大多数其实是在识别 logo、二维码这些噪声。去掉之后「参与 OCR」从 82 降到 8，是更诚实的口径，知识图谱也相应从 388/643 微调到 386/641。

实现上还踩过一个不太好查的坑：EasyOCR 底层用 `cv2.imread` 读图，而它在 Windows 上读不了中文路径，会静默返回空、随后报 `NoneType` 没有 `shape`。因为我们的项目路径里带中文，OCR 一度整体失效。解决办法是改用 `PIL.Image` 读图、转成 `numpy` 数组再喂给 EasyOCR，绕开 OpenCV 对中文路径的限制。

6 实验结果

6.1 抽取覆盖率

118 篇文档上各字段的填充率见表 2。平均填充 3.88 个字段，有 107 篇（91%）凑齐了关键要素、算作有效事件。

表 2：各信息点在 118 篇上的填充率

信息点	填充率	说明
灾害类型	118/118（100%）	入库即要求命中灾害类型
发生时间	103/118（87%）	正则多模式 + NER（时间）
发生地点	85/118（72%）	NER 与正则协同，经规范化只保留具体行政区划
救援信息	80/118（68%）	触发词 + 机构；权威源重点报道处置与救援力量
响应级别	49/118（42%）	启动应急响应的事件含；支持中文「四级」→ 级归一化
伤亡情况	14/118（12%）	含具体伤亡数字的事件
经济损失	9/118（8%）	披露直接经济损失金额的事件

这张表里有两点值得展开。其一，伤亡和经济损失的填充率明显偏低，这不是抽取的缺陷，而是真实信息源的特点：权威媒体的即时通报往往先讲清楚类型、时间、地点和响应级别，具体的伤亡和损失数字通常要等后续的跟踪报道才披露。我们认为如实呈现这一现象比硬凑数字更诚实，也更符合「不编造数据」的要求。其二，发生地点的 72% 是收紧后的结果。在做行政区划规范化之前，地点字段的填充率看着有 94%，但里面混着「家住某县县」「部署重点地区」「南方地区」这类噪声；规范化之后收敛到 72%，但留下的全是干净、具体的行政区划。我们宁愿用一点召回换取精度，因为在人工评价里，脏地点会被直接判错，得不偿失。

6.2 人工评价

抽取结果页的每个字段旁都有「正确 / 部分 / 错误」三个按钮，评分者点击后分别按 1.0 / 0.5 / 0.0 计分，系统实时返回这次的准确率和逐字段统计并写入评价库，可在汇总页按字段聚合查看。交付的版本里评价库是干净的初始状态，分数由评分者现场打出来，是真实记录而非预置。

7 对环境与社会可持续发展的影响

环境方面，爬虫的异步并发与礼貌抓取减少了无效请求，SimHash 去重避免了重复存储，抽取结果、OCR 与图谱都是一次构建、持久化复用，加上用的是 EasyOCR、jieba 这类 CPU 友好的模型，整体算力和能耗都比较低。社会方面，把散落在新闻里的灾情要素自动结构化、再关联

成事件图谱，可以为应急响应和防灾减灾提供线索，服务公共安全；OCR 把图片里的灾情信息也补了进来，提升了应急信息的完整度。系统内设 /sustainability 页面对此做了说明。

8 局限与展望

伤亡和经济损失的填充率受信息源披露习惯的限制，后续可以做跨文档的事件归并，把同一场灾害的即时通报和后续跟踪报道关联起来补全数字。NER 目前是 jieba 词性标注加领域规则，灾害领域的专名（细粒度地名、救援机构）还可以靠领域词典、微调，或在有条件时接入 LAC、HanLP 来增强。知识图谱也可以再往前走一步，做事件去重和时序链，支撑同一灾害多篇报道的聚合。

9 运行与复现

系统已附带抽取结果、知识图谱与 OCR 缓存，开箱即可启动：

```
pip install -r requirements.txt
python run.py web # 启动 Web, 默认 http://127.0.0.1:8090
# 从零构建（可选）：
python run.py crawl --max 400 # 异步爬取真实灾害新闻
python run.py ocr # EasyOCR 识别配图文字并回灌
python run.py extract # 全量集成抽取 + 构建知识图谱
```

启动后可访问抽取、知识图谱、OCR 抽取、抽取评价与可持续等页面。NER 默认使用 jieba，无需联网下载；仅从零跑 OCR 或「实时重新识别」时，首次会联网下载 EasyOCR 模型，之后离线复用。